

Documentacao Tecnica Completa

Pipeline: dengue_warehouse

Pipeline E2E de notificacoes de dengue (SINAN/DATASUS) com transformacao PySpark, carga em Data Warehouse dimensional (PostgreSQL) e modulo de qualidade e governanca de dados.

Gerado em 14/08/2026 16:22

1. Visao Geral

Este pipeline automatiza a coleta, tratamento, carga e governanca de dados de notificacoes de dengue publicadas pelo SINAN/DATASUS, cruzadas com dados populacionais do IBGE por Unidade Federativa. O objetivo e produzir um Data Warehouse dimensional confiavel (esquema estrela) e, ao mesmo tempo, medir e documentar a qualidade dos dados em cada estagio do processo -- do dado bruto, como chega do governo, ate a carga final no DW.

O pipeline e dividido em duas grandes etapas, executadas em sequencia por `run_pipeline()`: (1) download e transformacao dos dados brutos, com PySpark, incluindo checagens de qualidade no dado bruto e no consolidado; e (2) carga no Data Warehouse via padrao ELT (staging + resolucao de chaves em SQL), seguida de checagens de qualidade pos-carga, atualizacao do dashboard de governanca e geracao de documentacao (dicionario de dados, docs de codigo, diagramas de arquitetura).

Principais capacidades:

- Download automatizado (Selenium + requests) dos CSVs anuais do SINAN e da planilha de populacao do IBGE.
- Transformacao em PySpark (com fallback em pandas), incluindo deteccao automatica de encoding/separador e mapeamento tolerante a sinonimos de coluna.
- Framework de qualidade de dados em 4 dimensoes (completude, unicidade, validade de dominio, validade de range), aplicado em 3 momentos: bruto, pre-carga e pos-carga.
- Carga otimizada via padrao ELT: staging UNLOGGED + resolucao de chaves dimensionais via hash join em SQL, em vez de loop linha a linha em Python.
- DW de governanca separado (`dw_dengue_qualidade`), com esquema estrela proprio, particionado por mes, pronto para conectar direto no Power BI.
- Dashboard HTML autocontido (Chart.js) e dicionario de dados em PDF, gerado a partir do schema real do banco.
- Diagramas de arquitetura/linhagem em Mermaid, exportados tambem como imagem JPG.

2. Arquitetura

O fluxo de dados ponta a ponta parte dos CSVs brutos do SINAN e da planilha de populacao do IBGE, passa por uma etapa de transformacao (PySpark) que gera um snapshot de qualidade ANTES de qualquer normalizacao (etapa 'bruto') e outro logo apos a limpeza (etapa 'pre_carga'), e entao carrega os dados no banco dw_dengue atraves de uma area de staging transiente. A partir da staging, as chaves dimensionais (UF, tempo, perfil de vitima) sao resolvidas via JOIN em SQL, favorecendo o otimizador de consultas do Postgres (hash join) em vez de um loop Python linha a linha. Apos a carga, uma terceira rodada de checagens ('pos_carga') roda direto nas tabelas finais do DW.

Todas as checagens de qualidade, das 3 etapas, sao gravadas em um segundo banco (dw_dengue_qualidade), com esquema estrela proprio e particionado por mes -- permitindo acompanhar a evolucao da qualidade ao longo de multiplas execucoes do pipeline, e servir de fonte direta para dashboards de governanca no Power BI.

Fluxo ponta a ponta




Figura 1 -- Fluxo de dados do SINAN/IBGE ate o dashboard e o Power BI.

Bancos e responsabilidades




Figura 2 -- Tabelas de dw_dengue (Data Warehouse) e dw_dengue_qualidade (governanca), e como se relacionam.

Legenda das etapas de qualidade

Etapa	Quando roda	O que mede
bruto	Antes de qualquer normalizacao	Qualidade real do dado como sai do SINAN
pre_carga	Apos a limpeza (Spark/pandas), antes do DW	Efeito da transformacao na qualidade
pos_carga	Apos carregado em dw_dengue	Fidelidade do processo de carga (staging + JOIN)

3. Guia de Execucao Passo a Passo

1. Instalar dependencias Python

pip install pandas psycpg2-binary requests selenium webdriver-manager pyspark openpyxl xlrd plotly tqdm reportlab pdoc

2. Instalar Java e configurar HADOOP_HOME

O PySpark exige Java instalado e JAVA_HOME configurado. No Windows, defina tambem HADOOP_HOME apontando para uma instalacao minima do Hadoop (necessaria pelo winutils.exe), ex: C:\Hadoop.

3. Criar os dois bancos PostgreSQL

Criar os bancos dw_dengue (Data Warehouse principal) e dw_dengue_qualidade (governanca) na mesma instancia Postgres. O pipeline cria o schema de governanca sozinho (ensure_governanca_schema), mas as tabelas de dw_dengue (dim_uf, dim_tempo, dim_vitima, fato_dengue) sao pre-existentes e precisam ser criadas manualmente antes da primeira execucao.

4. Ajustar as credenciais de conexao

Revisar DB_CONFIG e DB_CONFIG_GOVERNANCA no topo do script (host, porta, usuario, senha) conforme o ambiente local.

5. Definir a estrategia de execucao (opcional)

USE_SPARK_TRANSFORM=True usa PySpark (recomendado para o volume completo, 16M+ linhas); USE_STAGING_LOAD=True usa a carga ELT otimizada via staging. GENERATE_HEAVY_DOCUMENTATION=True gera todos os artefatos de documentacao ao final -- pode ser desligado durante testes/depuracao para iterar mais rapido.

6. Executar o pipeline completo

Rodar como script: python pipeline_dengue_otimizado.py. Em notebook, chamar run_pipeline() diretamente (preferir rodar como script de verdade para que a geracao de docs de codigo via pdoc funcione sem precisar informar source_path manualmente).

7. Acompanhar a execucao pelos logs

Cada execucao gera um arquivo de log em pipeline_dengue/logs/pipeline_AAAAMMDD_HHMMSS.log, com o detalhamento completo de cada etapa, incluindo os scores de qualidade.

8. Conferir os artefatos gerados

Em pipeline_dengue/output/: dashboard_governanca.html, dicionario_dados.pdf, documentacao_completa_pipeline.pdf, arquitetura_pipeline.md/.jpg e docs_codigo/ (site HTML via pdoc).

9. Conectar o Power BI ao DW de governanca

Obter Dados -> Banco de Dados -> PostgreSQL, apontando para dw_dengue_qualidade. Usar a view materializada mv_governanca_qualidade para dashboards rapidos (ja com os JOINS prontos), ou o esquema dimensional completo para modelagem propria.

4. Dicionario de Dados

Schema estatico, gerado a partir das constantes do proprio codigo do pipeline (COLUNAS_ALVO, FLAG_COLS, etc.) -- garante que o dicionario nunca fica desatualizado se uma coluna for adicionada ou removida. Para a versao que le o schema REAL do banco (incluindo comentarios aplicados via COMMENT ON), use `generate_data_dictionary_pdf_live()`.

staging_dengue (dw_dengue · Staging (ELT, transiente))

Area de passagem: recebe o CSV consolidado via COPY, com valores ja normalizados mas ainda sem chaves substitutas resolvidas. Tabela UNLOGGED, truncada e recarregada a cada execucao do pipeline.

Coluna	Tipo	Dominio / Regra	Descricao
ano_nasc	INTEGER	1900-2026	Ano de nascimento do paciente.
cs_sexo	VARCHAR(2)	M, F ou I (Ignorado)	Sexo do paciente.
sg_uf	VARCHAR(2)	Sigla de UF (2 letras), uma das 27 unidades federativas	Sigla da UF de residencia do paciente.
dt_invest	VARCHAR(10) / texto dd/mm/aaaa	Data valida no formato dd/mm/aaaa	Data de investigacao do caso.
nu_anos	INTEGER	1900-2027	Ano de referencia da notificacao.
dt_notific	VARCHAR(10) / texto dd/mm/aaaa	Data valida no formato dd/mm/aaaa	Data de notificacao do caso ao sistema de vigilancia.
cs_gestant	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Idade gestacional, se aplicavel.
mialgia	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: mialgia (dor muscular).
cefaleia	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: cefaleia (dor de cabeca).
exantema	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: exantema (erupcao cutanea).
vomito	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: vomito.
nausea	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: nausea.
dor_costas	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: dor nas costas.
conjuntvit	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: conjuntivite.
artrite	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: artrite.
artralgia	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: artralgia (dor articular).
petequia_n	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: petequias.
leucopenia	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Achado laboratorial: leucopenia.
laco	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Resultado da prova do laco.
dor_retro	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: dor retro-orbital.
diabetes	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: diabetes mellitus.
hematolog	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: doenca hematologica.
hepatopati	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: hepatopatia.
renal	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: doenca renal.
hipertensa	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: hipertensao arterial.
auto_imune	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: doenca autoimune.
alarm_hipot	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: hipotensao.
alarm_plaq	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: queda no numero de plaquetas.

Coluna	Tipo	Dominio / Regra	Descricao
alm_vom	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: vomitos persistentes.
alm_sang	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: sangramento de mucosa.
alm_hemat	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: aumento do hematocrito.
alm_abdom	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: dor abdominal intensa e continua.
alm_letar	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: letargia ou irritabilidade.
alm_hepat	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: hepatomegalia.
alm_liq	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: acumulo de liquidos (derrame).
grav_pulso	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: pulso fraco/ausente.
grav_conv	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: convulsao.
grav_ench	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: enchimento capilar lento.
grav_insuf	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: insuficiencia respiratoria.
grav_taqui	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: taquicardia.
grav_extre	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: extremidades frias e palidas.
grav_hipot	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: hipotensao arterial/choque.
grav_hemat	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: hematemese.
grav_melen	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: melena.
grav_metro	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: metrorragia.
grav_sang	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: sangramento grave.
grav_ast	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: aumento de AST/ALT.
grav_mioc	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: miocardite.
grav_consc	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: alteracao do nivel de consciencia.
grav_orgao	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: comprometimento grave de outro orgao.
hospitaliz	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Indica se houve hospitalizacao do paciente.
evolucao	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Evolucao clinica do caso (cura, obito, etc).
dt_encerra	VARCHAR(10) / texto dd/mm/aaaa	Data valida no formato dd/mm/aaaa	Data de encerramento/conclusao do caso.

dim_uf (dw_dengue · Dimensao)

Unidades federativas do Brasil, com populacao (fonte IBGE) e regio geografica.

Coluna	Tipo	Dominio / Regra	Descricao
sk_uf	SERIAL	PK	Chave substituta (surrogate key).
sg_uf	VARCHAR(2)	UNIQUE, 27 UFs	Sigla da UF.
populacao_uf	INTEGER	>= 0	Populacao estimada (IBGE).
regiao	VARCHAR(20)	Norte/Nordeste/Centro-Oeste/Sudeste/Sul	Regiao geografica.

dim_tempo (dw_dengue · Dimensao)

Calendario completo (uma linha por data), usada por todas as datas do fato.

Coluna	Tipo	Dominio / Regra	Descricao
sk_tempo	SERIAL	PK	Chave substituta.
data_completa	DATE	UNIQUE	Data no formato ISO.
data_formatada	VARCHAR(10)	-	Data formatada dd/mm/aaaa.
ano	INTEGER	-	Ano da data.
semestre	INTEGER	1-2	Semestre do ano.
trimestre	INTEGER	1-4	Trimestre do ano.
mes	INTEGER	1-12	Mes do ano.
nome_mes	VARCHAR(15)	-	Nome do mes por extenso, em portugues.
dia	INTEGER	1-31	Dia do mes.
dia_semana_num	INTEGER	1-7	Dia da semana (1=Segunda).
nome_dia_semana	VARCHAR(15)	-	Nome do dia da semana, em portugues.
semana_ano	INTEGER	1-53	Numero da semana no ano (ISO).
fim_de_semana	BOOLEAN	-	Indica se a data cai em sabado/domingo.

dim_vitima (dw_dengue · Dimensao)

Perfis unicos de paciente (sexo, gestacao, comorbidades). Uma linha por combinacao distinta encontrada nos dados.

Coluna	Tipo	Dominio / Regra	Descricao
sk_vitima	SERIAL	PK	Chave substituta.
cs_sexo	VARCHAR(2)	M/F//NI	Sexo do paciente.
cs_gestant	SMALLINT	1=Sim,2=Nao,9=Ignorado	Gestante.
diabetes	SMALLINT	1=Sim,2=Nao,9=Ignorado	Comorbidade: diabetes.
hematolog	SMALLINT	1=Sim,2=Nao,9=Ignorado	Comorbidade: doenca hematologica.
hepatopati	SMALLINT	1=Sim,2=Nao,9=Ignorado	Comorbidade: hepatopatia.
renal	SMALLINT	1=Sim,2=Nao,9=Ignorado	Comorbidade: doenca renal.
hipertensa	SMALLINT	1=Sim,2=Nao,9=Ignorado	Comorbidade: hipertensao.
auto_imune	SMALLINT	1=Sim,2=Nao,9=Ignorado	Comorbidade: doenca autoimune.
possui_comorbidade	SMALLINT	0/1	Flag derivada: 1 se qualquer comorbidade acima = Sim.

fato_dengue (dw_dengue · Fato)

Fato de notificacoes de dengue, grao = 1 linha por combinacao de UF/tempo/perfil de vitima/sintomas. Carregada a partir da staging via JOIN.

Coluna	Tipo	Dominio / Regra	Descricao
sk_fato	BIGSERIAL	PK	Chave substituta do fato.
sk_uf	INTEGER	FK -> dim_uf	UF de residencia.
sk_tempo_notific	INTEGER	FK -> dim_tempo	Data de notificacao.
sk_tempo_invest	INTEGER	FK -> dim_tempo	Data de investigacao.
sk_tempo_encerra	INTEGER	FK -> dim_tempo	Data de encerramento.

Coluna	Tipo	Dominio / Regra	Descricao
sk_vitima	INTEGER	FK -> dim_vitima	Perfil do paciente.
ano_nasc	INTEGER	1900-2026	Ano de nascimento do paciente.
cs_sexo	VARCHAR(2)	M, F ou I (Ignorado)	Sexo do paciente.
nu_ano	INTEGER	1900-2027	Ano de referencia da notificacao.
cs_gestant	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Idade gestacional, se aplicavel.
mialgia	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: mialgia (dor muscular).
cefaleia	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: cefaleia (dor de cabeca).
exantema	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: exantema (erupcao cutanea).
vomito	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: vomito.
nausea	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: nausea.
dor_costas	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: dor nas costas.
conjuntvit	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: conjuntivite.
artrite	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: artrite.
artralgia	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: artralgia (dor articular).
petequia_n	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: petequias.
leucopenia	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Achado laboratorial: leucopenia.
laco	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Resultado da prova do laco.
dor_retro	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sintoma: dor retro-orbital.
diabetes	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: diabetes mellitus.
hematolog	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: doenca hematologica.
hepatopati	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: hepatopatia.
renal	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: doenca renal.
hipertensa	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: hipertensao arterial.
auto_imune	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Comorbidade: doenca autoimune.
alm_hipot	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: hipotensao.
alm_plaq	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: queda no numero de plaquetas.
alm_vom	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: vomitos persistentes.
alm_sang	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: sangramento de mucosa.
alm_hemat	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: aumento do hematocrito.
alm_abdom	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: dor abdominal intensa e continua.
alm_letar	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: letargia ou irritabilidade.
alm_hepat	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: hepatomegalia.
alm_liq	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de alarme: acumulo de liquidos (derrame).
grav_pulso	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: pulso fraco/ausente.
grav_conv	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: convulsao.
grav_ench	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: enchimento capilar lento.
grav_insuf	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: insuficiencia respiratoria.
grav_taqui	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: taquicardia.

Coluna	Tipo	Dominio / Regra	Descricao
grav_extre	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: extremidades frias e palidas.
grav_hipot	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: hipotensao arterial/choque.
grav_hemat	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: hematemese.
grav_melen	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: melena.
grav_metro	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: metrorragia.
grav_sang	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: sangramento grave.
grav_ast	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: aumento de AST/ALT.
grav_mioc	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: miocardite.
grav_consc	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: alteracao do nivel de consciencia.
grav_orgao	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Sinal de gravidade: comprometimento grave de outro orgao.
hospitaliz	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Indica se houve hospitalizacao do paciente.
evolucao	SMALLINT	1=Sim, 2=Nao, 9=Ignorado	Evolucao clinica do caso (cura, obito, etc).

dim_dataset (dw_dengue_qualidade · Dimensao)

Cada pipeline/projeto que reporta metricas de qualidade a este DW (permite reuso por outros datasets alem do dengue).

Coluna	Tipo	Dominio / Regra	Descricao
sk_dataset	INT IDENTITY	PK	Chave substituta.
nome_dataset	VARCHAR(80)	UNIQUE	Nome do dataset/pipeline, ex: 'dengue_warehouse'.
descricao	VARCHAR(255)	-	Descricao livre do dataset.
responsavel	VARCHAR(120)	-	Responsavel pelo pipeline.
criado_em	TIMESTAMP	-	Data de primeiro registro do dataset.

dim_ativo (dw_dengue_qualidade · Dimensao)

Tabela/coluna alvo de cada checagem de qualidade -- o 'onde' da regra.

Coluna	Tipo	Dominio / Regra	Descricao
sk_ativo	INT IDENTITY	PK	Chave substituta.
tabela	VARCHAR(120)	-	Nome da tabela checada.
coluna	VARCHAR(120)	NULL = tabela inteira	Nome da coluna checada.

dim_dimensao_qualidade (dw_dengue_qualidade · Dimensao)

As dimensoes formais de qualidade de dados aplicadas pelo framework (base teorica: Wang, Naumann).

Coluna	Tipo	Dominio / Regra	Descricao
sk_dimensao	SMALLINT IDENTITY	PK	Chave substituta.
nome_dimensao	VARCHAR(30)	completude/unicidade/validade e dominio/validade_range	Nome da dimensao de qualidade.

Coluna	Tipo	Dominio / Regra	Descricao
descricao	VARCHAR(255)	-	Descricao da dimensao.

dim_tempo_execucao (dw_dengue_qualidade · Dimensao)

Uma linha por execucao do pipeline que reportou qualidade.

Coluna	Tipo	Dominio / Regra	Descricao
sk_tempo_execucao	INT IDENTITY	PK	Chave substituta.
timestamp_execucao	TIMESTAMP	UNIQUE	Instante exato da execucao.
data_execucao	DATE	-	Data da execucao (chave de particionamento do fato).
ano/mes/dia/hora	SMALLINT	-	Atributos derivados do timestamp.
dia_semana_num	SMALLINT	1-7	Dia da semana da execucao.

fato_dq_metrica (dw_dengue_qualidade · Fato (particionada por mes))

Grao = 1 checagem de qualidade, de 1 coluna, de 1 dataset, numa execucao. Particionada por mes (data_execucao) para suportar grande volume de execucoes ao longo do tempo.

Coluna	Tipo	Dominio / Regra	Descricao
sk_metrica	BIGINT IDENTITY	PK (composta com data_execucao)	Chave substituta do fato.
data_execucao	DATE	-	Chave de particionamento (mensal).
sk_dataset	INT	FK -> dim_dataset	Pipeline/dataset checado.
sk_tempo_execucao	INT	FK -> dim_tempo_execucao	Execucao que gerou a metrica.
sk_ativo	INT	FK -> dim_ativo	Tabela/coluna checada.
sk_dimensao	SMALLINT	FK -> dim_dimensao_qualidade	Dimensao de qualidade aplicada.
etapa	VARCHAR(20)	bruto/pre_carga/pos_carga	Estagio do pipeline em que a checagem rodou.
passou	BOOLEAN	-	Se a checagem foi aprovada.
taxa	NUMERIC(7,4)	0.0-1.0	Taxa de conformidade (completude/validade).
qtd_violacoes	BIGINT	>= 0	Quantidade de registros em violacao.
total_linhas	BIGINT	>= 0	Total de linhas avaliadas.
detalhe	JSONB	-	Detalhes adicionais (exemplos de valores invalidos, thresholds, etc).

5. Troubleshooting -- Problemas Resolvidos

Registro dos problemas reais encontrados durante o desenvolvimento deste pipeline, com sintoma, causa raiz e a correcao aplicada -- util tanto como referencia futura quanto como evidencia do processo iterativo de engenharia de dados por tras do projeto.

5.1. VACUUM executado dentro de um bloco de transacao

Sintoma: ERRO NA CARGA apos a etapa de recriacao de indices/PK de fato_dengue: "VACUUM nao pode ser executado dentro de um bloco de transacao", mesmo com toda a carga (16M+ linhas) ja concluida com sucesso.

Causa: VACUUM e um dos poucos comandos do Postgres que exige autocommit=True. A conexao psycopg2 usa autocommit=False por padrao, e os comandos anteriores (recreate_primary_key, recreate_indexes, set_autovacuum) ja tinham aberto uma transacao implicita no momento em que VACUUM ANALYZE fato_dengue era chamado.

Correcao aplicada: Antes do VACUUM: conn.commit() para fechar a transacao pendente, depois conn.autocommit = True apenas pela duracao do comando, revertendo para False logo em seguida (bloco try/finally). O tratamento de erro (except Exception) tambem forca conn.autocommit = False antes de tentar rollback, garantindo que o restante do fluxo de erro continue funcionando mesmo se a falha ocorrer durante o VACUUM.

5.2. Py4JJavaError / BindException ao criar a SparkSession

Sintoma: java.net.BindException: Cannot assign requested address -- Service 'sparkDriver' failed after 16 retries, ao chamar create_spark_session().

Causa: O Spark tenta autodetectar o hostname/IP da maquina para abrir o socket do driver. Em maquinas Windows com multiplas interfaces de rede (Wi-Fi, VPN, adaptadores virtuais de Docker/WSL), essa autodeteccao com frequencia escolhe um endereco que a propria maquina nao consegue bindar.

Correcao aplicada: Forcar o driver a usar loopback (127.0.0.1) em vez de autodetectar: os.environ['SPARK_LOCAL_IP'] = '127.0.0.1' (setado antes de qualquer inicializacao da JVM) e as configs spark.driver.host / spark.driver.bindAddress = '127.0.0.1' no SparkSession.builder.

5.3. NameError: '__file__' nao existe (gerar docs do codigo em notebook)

Sintoma: generate_code_documentation() levantava NameError ao tentar Path(__file__), derrubando o pipeline mesmo com a carga inteira ja concluida com sucesso -- run_pipeline() so capturava RuntimeError, nao NameError.

Causa: '__file__' so existe quando o Python executa um arquivo .py de verdade a partir do disco. Rodando em notebook (Jupyter/.ipynb, VS Code Interactive Window), o codigo roda celula por celula dentro de um kernel -- nao ha um .py sendo executado.

Correcao aplicada: generate_code_documentation() passou a aceitar um parametro opcional source_path; na ausencia dele, tenta __file__ dentro de um try/except NameError e converte a falha em RuntimeError com mensagem clara -- que run_pipeline() ja sabia tratar sem derrubar o restante do fluxo.

5.4. InternalCompilerException: Code grows beyond 64 KB (Janino)

Sintoma: WARN no log durante a transformacao PySpark: falha ao compilar codigo Java gerado pelo whole-stage codegen, seguido de 'Whole-stage codegen disabled for plan'.

Causa: O formato .class da JVM tem limite fixo de 64 KB de bytecode por metodo. A funcao `as_flag_spark()` gera uma cadeia extensa de CASE WHEN (`upper/trim/translate/regexp_extract`) repetida para cada uma das ~44 colunas de `FLAG_COLS`, tudo compilado em um unico metodo Java -- que ultrapassa o limite.

Correcao aplicada: Nao e um erro fatal: o Spark ja detecta a falha e cai automaticamente para execucao interpretada (mais lenta, porem correta) para aquela etapa. Para reduzir a ocorrencia e o custo das tentativas de compilacao fracassadas, foi adicionada a config `spark.sql.codegen.methodSplitThreshold = 10`, que faz o Catalyst dividir metodos grandes em varios menores automaticamente.

5.5. Diagrama de arquitetura em Markdown nao e uma imagem

Sintoma: O arquivo `arquitetura_pipeline.md` so exhibe os diagramas visualmente em ferramentas que interpretam blocos ````mermaid` (GitHub, VS Code com extensao); nao abre como imagem em visualizadores comuns, PowerPoint, Word, etc.

Causa: Mermaid e uma linguagem de marcacao de diagramas em texto puro -- o .md contem o CODIGO do diagrama, nao a imagem renderizada.

Correcao aplicada: Adicionada a funcao `render_mermaid_to_jpg()`, que envia o codigo Mermaid para APIs publicas de renderizacao (`mermaid.ink` como primeira tentativa, `kroki.io` como fallback automatico) e salva o retorno como .jpg de verdade. `generate_architecture_diagram()` agora gera .md E .jpg dos dois diagramas, de forma defensiva (se nao houver internet, apenas registra um aviso no log sem interromper o pipeline).

5.6. NameError: 'generate_architecture_diagram' is not defined

Sintoma: `run_pipeline()` falhava com `NameError` ao chamar `generate_architecture_diagram()`, mesmo a funcao aparentando existir no arquivo.

Causa: Erro de edicao: ao inserir a nova funcao `render_mermaid_to_jpg()` antes de `generate_architecture_diagram()`, a linha `'def generate_architecture_diagram(output_path: Path = None) -> Path:'` foi removida acidentalmente, deixando o corpo da funcao 'orfao' -- codigo solto no modulo, sem nenhuma funcao envolvendo-o, portanto o nome nunca era registrado no namespace do modulo.

Correcao aplicada: Restaurada a linha de definicao da funcao no ponto correto, e adicionada uma checagem estatica (AST parsing) para confirmar que todas as funcoes referenciadas no pipeline existem de fato no escopo do modulo, prevenindo regressoes semelhantes.